

Credit Risk Scorecard

Análisis y Modelado de Riesgo Crediticio

1. Contexto de Negocio

Este proyecto construye un sistema de scoring crediticio siguiendo los estándares de la industria bancaria (Basel II). El objetivo es predecir la probabilidad de que un cliente entre en mora grave (90+ días) en los próximos 2 años, asignando una puntuación entre 300 y 850 donde mayor puntuación indica menor riesgo.

2. Dataset

Campo	Valor
Fuente	Give Me Some Credit — Kaggle
Registros	150,000 clientes
Variables	11 (10 predictoras + 1 target)
Target	Mora grave en los próximos 2 años
Tasa de incumplimiento	6.68%

3. Hallazgos del Análisis Exploratorio

El análisis exploratorio reveló patrones claros de riesgo crediticio. El dataset presenta un desbalanceo significativo con solo el 6.68% de defaults. Las variables más predictivas son el historial de moras previas y la utilización del crédito rotativo.




Figura 1 — Tasa de default por segmento de edad




Figura 2 — Tasa de default por utilización de crédito




Figura 3 — Tasa de default por historial de mora 90+ días

4. Metodología del Modelo

Se utilizó la metodología estándar de scoring crediticio basada en Weight of Evidence (WoE) e Information Value (IV) para la transformación y selección de variables, seguida de una Regresión Logística como modelo base. Esta metodología es la más utilizada en la industria bancaria por su interpretabilidad y cumplimiento regulatorio (Basel II).

Etapa	Técnica	Herramienta
Selección de variables	Information Value (IV)	Scorecardpy
Transformación	Weight of Evidence (WoE)	Scorecardpy
Modelo	Regresión Logística	Scikit-learn
Validación	AUC-ROC, Gini, KS	Scikit-learn
Escala final	PDO 20 puntos	Scorecardpy

5. Resultados del Modelo

Métrica	Valor obtenido	Benchmark industria	Estado
---------	----------------	---------------------	--------

AUC-ROC	0.8495	> 0.70	✓ Supera
Gini	0.6989	> 0.35	✓ Supera
KS Statistic	0.5474	> 0.30	✓ Supera




Figura 4 — Curva ROC del modelo (AUC = 0.8495)

6. Scorecard y Segmentación de Cartera

El modelo fue convertido a un scorecard con escala 300-850 siguiendo la metodología PDO (Points to Double Odds = 20). La segmentación de cartera permite definir políticas crediticias claras por rango de riesgo.

Rango	% Cartera	Tasa Default	Política
Muy bajo (750+)	6.9%	0.4%	Aprobar automáticamente
Bajo (700-750)	58.3%	1.7%	Aprobar condiciones estándar
Moderado (650-700)	26.7%	9.5%	Revisar manualmente
Alto (600-650)	6.1%	35.0%	Pedir garantías
Crítico (<600)	1.9%	51.2%	Rechazar




Figura 5 — Distribución de credit scores por grupo de riesgo

7. Conclusiones

El modelo desarrollado supera todos los benchmarks de la industria bancaria. Las tres variables más predictivas son el historial de mora 90+ días, la utilización del crédito rotativo y las moras de 30-59 días. El scorecard permite clasificar el 65% de la cartera como bajo riesgo con tasas de default inferiores al 2%, mientras identifica el 8% de clientes de alto riesgo con tasas superiores al 35%.

8. Stack Tecnológico

Herramienta	Uso
Python 3.10	Lenguaje principal
Pandas / NumPy	Manipulación de datos
Matplotlib / Seaborn	Visualización
DuckDB	SQL analítico en local
Scikit-learn	Regresión logística
Scorecardpy	WoE, IV y scorecard
Power BI	Dashboard ejecutivo